



Disciplina de Engenharia de Dados

Utilização das unidades de saúde da atenção Primária de Maricá/RJ

Estudo a partir de relatórios do prontuário eletrônico Vitacare

Aluno: Almir de Souza Pontes Junior

Email: pontes@pontesti.com.br

Github: https://github.com/Pontes/pucrio_mvp_eng_dados

Sumário

1. CONTEXTUALIZAÇÃO E OBJETIVOS GERAIS	3
2. DADOS E FERRAMENTAS SELECIONADAS	4
3. CARGA DOS DADOS – CAMADA BRONZE	5
3.1 O QUE FOI REALIZADO	5
3.2 POR QUE A BRONZE FOI CRIADA DESSA MANEIRA	6
3.3 ARQUIVOS, ARTEFATOS E TECNOLOGIA	6
3.4 EVIDÊNCIAS VISUAIS DA BRONZE	6
3.5 RECONCILIAÇÃO DA CARGA BRUTA	10
4. MODELAGEM E CATÁLOGO DE DADOS.....	11
4.1 ARQUITETURA MEDALHÃO	11
4.2 CAMADA SILVER	11
4.4 CATÁLOGO	16
5. PIPELINE DE DADO	17
6. QUALIDADE DE DADOS.....	19
7. ANÁLISE DE DADOS	21
7.1 VOLUME DE CONSULTAS	21
7.2 PACIENTES E UNIDADES	21
7.3 DIABETES E HIPERTENSÃO	21
7.4 O QUE ESTA VERSÃO NÃO RESPONDE	23
8. CONSIDERAÇÕES FINAIS E AUTOAVALIAÇÃO.....	23
8.1 PONTOS DE MELHORIA	23
8.2 AUTOAVALIAÇÃO.....	24

1. Contextualização e objetivos gerais

O presente trabalho tem como objeto a utilização das unidades de saúde da atenção primária no município de Maricá, a partir de extratos do sistema Vitacare. Integra o MVP da disciplina de Engenharia de Dados da PUC-Rio. O enunciado pede um pipeline na nuvem, com progressão clara de camadas e proteção de informações sensíveis antes do envio a ambiente externo.

O objetivo é organizar os dados para entender como os pacientes utilizam as unidades da rede. A proposta inicial incluía análises por bairro, período e unidade. Nesta versão, o foco ficou no volume de consultas, nos pacientes atendidos, no uso de mais de uma unidade e nos grupos de acompanhamento de diabetes e hipertensão. A análise tem caráter descritivo, sem investigar relações de causa e efeito dos tratamentos ou a prevalência na população.

Os dados analisados na nuvem contêm 312.339 registros de consultas, de 1º de agosto a 30 de dezembro de 2025, com 88.992 pacientes atendidos em 27 unidades. As extrações dos arquivos vão de setembro de 2025 a janeiro de 2026. A extração acontece no mês seguinte ao dos atendimentos: setembro de 2025 corresponde às consultas de agosto. Por isso, as análises temporais usam a data da consulta, e não o mês indicado no nome do arquivo.

Perguntas do estudo e o que esta versão responde:

Pergunta	Situação nesta versão
1. Quantos registros de consulta existem por dia, mês e unidade?	Consultas agregadas por período e unidade. O volume mensal está consolidado.
2. Quantos pacientes distintos foram atendidos por unidade e na rede?	Contagem na rede (88.992) e análises por unidade, pelo código interno estável.
3. Quantos atendimentos cada paciente teve no período?	Abordagem parcial, com médias agregadas por faixa etária e por grupo de acompanhamento.
4. De quais bairros vêm os pacientes de cada unidade?	Ficou para uma próxima etapa, após revisão dos bairros e dos vínculos cadastrais.
5. Quantos pacientes utilizaram mais de uma unidade?	1.204 pacientes; identificação de unidades que compartilham pacientes.
6. Por quais profissionais e categorias os pacientes foram atendidos?	Ficou para uma próxima etapa. Foram verificadas 459 consultas sem identificador de profissional.
7. Onde estão os problemas de qualidade?	Campos essenciais, datas, identificadores e relacionamentos foram avaliados.
8. Como o uso varia ao longo dos meses?	Comparação do volume mensal de agosto a dezembro de 2025.
Como se distribuem os pacientes nos planos de diabetes e hipertensão?	Três grupos exclusivos, com consultas e média por paciente atendido.

As análises complementares de exames, diagnósticos, procedimentos e condições domiciliares foram carregadas no pipeline, mas não foram desenvolvidas como resposta nesta entrega.

Pacientes distintos não são aditivos entre meses ou unidades. Compartilhar duas unidades não comprova encaminhamento. A comprovação formal das condições de autorização de uso dos dados Vitacare não está incluída nesta documentação.

2. Dados e ferramentas selecionadas

As fontes são relatórios CSV do Vitacare, no padrão Marica_<TIPO>_<AAAA-MM>.csv, em UTF-8 e separados por ponto e vírgula. As competências observadas vão de 2025-09 a 2026-01. Oito tipos de listagem e a listagem de login de profissionais foram ingeridos. O escopo inicial priorizou o cadastro de usuários e a listagem de consultas; as demais bases entraram na Bronze para permitir expansão.

Fonte	Tabela Bronze	Papel no estudo
LISTAGEM_CADASTRO_DO_USUARIO_CAP	csv_cadastro_usuario_cap	População vinculada às unidades
LISTAGEM_CONSULTAS_CAP	csv_consultas_cap	Eventos de consulta; base das análises
LISTAGEM_LOGIN	csv_listagem_login	Mapa local de profissionais
LISTAGEM_CONSOLIDADA	csv_consolidada	Produção registrada; não somada às consultas
SUBPAV_MENSAL_EXAMES	csv_exames	Carregada; análise fora desta entrega
ATENDIMENTO_COM_CID_PARAM_BIO	csv_atendimento_cid_param_bio	Carregada; análise fora desta entrega
SUBPAV_PLAN_ACOMP_MENSAL_DIAB	csv_acompanhamento_diab	Plano de diabetes
SUBPAV_PLAN_ACOMP_MENSAL_HIPER	csv_acompanhamento_hiper	Plano de hipertensão
SUB_PAV_FICHA_A_V2 (61 colunas)	csv_ficha_a_v2	Rejeitada na carga; não usar
SUB_PAV_FICHA_A_V2 (161 colunas)	csv_ficha_a_v2_ext	Somente a competência 2026-01

O tratamento restrito ficou no MySQL 8, em Docker (container mysql_db, schema vitacare_mvp). A preparação usa Python 3. Na Bronze, a leitura é feita com a biblioteca padrão csv, de propósito, para não inferir tipo numérico em CPF, CNS ou CNES. O hash SHA-256 (hashlib) evita recarregar o mesmo arquivo. Expressões regulares extraem a competência AAAA-MM e normalizam nomes de coluna. PyMySQL grava em lotes com comandos parametrizados. python-dotenv lê credenciais de um arquivo .env local, que não entra no repositório.

Na camada Silver, além das bibliotecas de conexão já utilizadas, foram incluídas e Unicode data para padronizar os documentos no ambiente local. Os testes com pytest verificam as regras de identificação e ingestão por meio de dados sintéticos, sem utilizar informações reais. Já pandas e pyarrow são utilizados apenas na etapa de exportação, para gerar os arquivos Parquet que serão enviados ao Databricks.

Na nuvem, o Databricks Free Edition recebe os Parquets no volume /Volumes/workspace/vitacare_mvp/entrada e persiste tabelas Delta no schema

workspace.vitacare_mvp. As consultas analíticas usam SQL. O gráfico de médias por grupo foi produzido em Python, convertendo apenas o resultado agregado para Pandas e utilizando Matplotlib.

Limitação de ferramenta: o envio dos Parquets ao volume e a execução do notebook ainda dependem de etapas manuais. Cargas com CREATE TABLE IF NOT EXISTS não atualizam sozinhas uma tabela Delta quando o arquivo de origem muda.

3. Carga dos dados – Camada Bronze

A camada Bronze é responsável por armazenar os dados conforme foram recebidos das fontes originais, sem realizar alterações. Essa etapa permite conferir os registros e manter sua rastreabilidade antes de qualquer tratamento. Nesta arquitetura, a Bronze fica armazenada em um banco MySQL local, pois os arquivos CSV contêm dados pessoais e informações de saúde. Somente após a preparação dos dados é que eles são enviados para a nuvem.

3.1 O que foi realizado

Todos os arquivos CSV disponíveis na pasta vitacare_fontes/ foram importados para o schema vitacare_mvp. Para cada tipo de listagem, foi criada uma tabela csv_*, mantendo todas as colunas originais como texto. Também foram adicionados os campos carga_id, linha_origem, arquivo_origem, data_importacao e competencia_extracao, que permitem identificar a origem de cada registro.

O controle das importações é realizado pela tabela carga_arquivo, que armazena o hash SHA-256 de cada arquivo, a quantidade de registros lidos, aceitos e rejeitados, além do status da importação. Quando uma linha apresenta um número de campos diferente do cabeçalho, ela é encaminhada para a tabela linha_rejeitada, com o motivo Q_LINHA_MALFORMADA. Dessa forma, os registros com problemas ficam documentados, sem serem descartados silenciosamente. Para conferir a integridade da importação, foi adotada a regra de que o total de linhas lidas deve ser igual à soma das linhas aceitas e rejeitadas.

No caso da Ficha A, foram identificados dois formatos diferentes: um com 61 colunas e outro com 161. Por esse motivo, os dados foram separados nas tabelas csv_ficha_a_v2 e csv_ficha_a_v2_ext. As quatro competências que apresentavam 61 colunas tiveram todos os registros rejeitados e, portanto, não devem ser utilizadas nas análises. Já o arquivo com 161 colunas, referente à competência de janeiro de 2026, foi aceito. Como o cabeçalho da Ficha A está incompleto, não é possível determinar com segurança o significado de todas as colunas, sendo necessário evitar interpretações baseadas apenas em suposições.

A implementação utiliza dois scripts principais. O scripts/ingest/apply_schema_vitacare_mvp.py aplica a estrutura do banco de dados definida no arquivo sql/10_schema_vitacare_mvp.sql. Já o scripts/ingest/import_bruto.py identifica os arquivos CSV disponíveis, cria as tabelas csv_* e

realiza a importação dos registros em lotes. As configurações de conexão com o banco de dados ficam centralizadas no arquivo `scripts/db.py`.

3.2 Por que a Bronze foi criada dessa maneira

A ingestão mantém os dados originais para permitir futuras conferências e auditorias. O mês de extração e a data do atendimento são armazenados em campos separados, evitando que o mês indicado no nome do arquivo seja confundido com o período em que a consulta ocorreu. O uso do hash também permite identificar arquivos já importados, impedindo que sejam carregados novamente.

Os dados que permitem identificar diretamente os pacientes permanecem apenas no MySQL local, reduzindo sua exposição. Essa medida, porém, não elimina a necessidade de avaliar a finalidade do uso dos dados, as informações que serão disponibilizadas e as autorizações institucionais necessárias.

Nesta etapa, optou-se por não utilizar a biblioteca `pandas`, evitando a conversão automática dos tipos de dados. Além disso, a leitura e a importação em lotes permitem trabalhar com arquivos grandes, como os da Ficha A, sem precisar carregá-los inteiramente na memória.

3.3 Arquivos, artefatos e tecnologia

Peça	Função na Bronze
<code>vitacare_fontes/</code>	CSV originais; fora do Git
<code>sql/10_schema_vitacare_mvp.sql</code>	Database, carga_arquivo e linha_rejeitada
<code>scripts/ingest/import_bruto.py</code>	Descoberta, criação dinâmica e carga
<code>scripts/ingest/apply_schema_vitacare_mvp.py</code>	Aplicação do DDL
<code>scripts/db.py</code>	Conexão parametrizada
MySQL 8 + Docker (<code>mysql_db</code>)	Ambiente restrito
<code>csv</code> , <code>hashlib</code> , <code>re</code> , <code>PyMySQL</code> , <code>python-dotenv</code>	Leitura fiel, hash, SQL e credenciais

3.4 Evidências visuais da Bronze

Abaixo segue as imagens de comprovação principal do tratamento medalhão na camada Bronze. A ordem sugerida vai da pasta de origem até a reconciliação e as rejeições.

Figura 1 – Fontes CSV disponíveis para a carga

Nome	Data de Modificação	Tamanho	Tipo
Marica_ATENDIMENTO_COM_CID_PARAM_BIO_2025-09.csv	24 de set. de 2025, 12:39	1,5 MB	Documento CSV
Marica_ATENDIMENTO_COM_CID_PARAM_BIO_2025-10.csv	2 de out. de 2025, 09:51	1,7 MB	Documento CSV
Marica_ATENDIMENTO_COM_CID_PARAM_BIO_2025-11.csv	4 de nov. de 2025, 09:00	1,7 MB	Documento CSV
Marica_ATENDIMENTO_COM_CID_PARAM_BIO_2025-12.csv	2 de dez. de 2025, 17:01	1,7 MB	Documento CSV
Marica_ATENDIMENTO_COM_CID_PARAM_BIO_2026-01.csv	3 de jan. de 2026, 06:53	1,7 MB	Documento CSV
Marica_LISTAGEM_CADASTRO_DO_USUARIO_CAP_2025-09.csv	2 de set. de 2025, 11:51	59,9 MB	Documento CSV
Marica_LISTAGEM_CADASTRO_DO_USUARIO_CAP_2025-10.csv	2 de out. de 2025, 09:50	59,7 MB	Documento CSV
Marica_LISTAGEM_CADASTRO_DO_USUARIO_CAP_2025-11.csv	4 de nov. de 2025, 08:58	60,2 MB	Documento CSV
Marica_LISTAGEM_CADASTRO_DO_USUARIO_CAP_2025-12.csv	2 de dez. de 2025, 17:00	59,8 MB	Documento CSV
Marica_LISTAGEM_CADASTRO_DO_USUARIO_CAP_2026-01.csv	3 de jan. de 2026, 06:52	59,6 MB	Documento CSV
Marica_LISTAGEM_CONSOLIDADA_2025-09.csv	2 de set. de 2025, 08:33	2,2 MB	Documento CSV
Marica_LISTAGEM_CONSOLIDADA_2025-10.csv	2 de out. de 2025, 05:53	2,4 MB	Documento CSV
Marica_LISTAGEM_CONSOLIDADA_2025-11.csv	4 de nov. de 2025, 01:21	2,6 MB	Documento CSV
Marica_LISTAGEM_CONSOLIDADA_2025-12.csv	2 de dez. de 2025, 17:14	2,7 MB	Documento CSV
Marica_LISTAGEM_CONSOLIDADA_2026-01.csv	2 de jan. de 2026, 23:27	2,8 MB	Documento CSV
Marica_LISTAGEM_CONSULTAS_CAP_2025-09.csv	2 de set. de 2025, 11:52	11,9 MB	Documento CSV
Marica_LISTAGEM_CONSULTAS_CAP_2025-10.csv	2 de out. de 2025, 09:50	12,1 MB	Documento CSV
Marica_LISTAGEM_CONSULTAS_CAP_2025-11.csv	4 de nov. de 2025, 08:59	14,4 MB	Documento CSV
Marica_LISTAGEM_CONSULTAS_CAP_2025-12.csv	2 de dez. de 2025, 17:00	11,5 MB	Documento CSV
Marica_LISTAGEM_CONSULTAS_CAP_2026-01.csv	3 de jan. de 2026, 06:52	10,2 MB	Documento CSV
Marica_LISTAGEM_LOGIN_2025-09.csv	2 de set. de 2025, 08:33	247 KB	Documento CSV
Marica_LISTAGEM_LOGIN_2025-10.csv	2 de out. de 2025, 05:53	249 KB	Documento CSV
Marica_LISTAGEM_LOGIN_2025-11.csv	4 de nov. de 2025, 01:21	258 KB	Documento CSV
Marica_LISTAGEM_LOGIN_2025-12.csv	2 de dez. de 2025, 08:36	107 KB	Documento CSV
Marica_LISTAGEM_LOGIN_2026-01.csv	2 de jan. de 2026, 23:27	204 bytes	Documento CSV
Marica_SUB_PAV_FICHA_A_V2_2025-09.csv	2 de set. de 2025, 11:49	327,4 MB	Documento CSV
Marica_SUB_PAV_FICHA_A_V2_2025-10.csv	2 de out. de 2025, 09:48	329,6 MB	Documento CSV
Marica_SUB_PAV_FICHA_A_V2_2025-11.csv	4 de nov. de 2025, 08:56	331,9 MB	Documento CSV
Marica_SUB_PAV_FICHA_A_V2_2025-12.csv	2 de dez. de 2025, 16:58	333,4 MB	Documento CSV
Marica_SUB_PAV_FICHA_A_V2_2026-01.csv	5 de jan. de 2026, 15:59	334,4 MB	Documento CSV
Marica_SUBPAV_MENSAL_EXAMES_2025-09.csv	2 de set. de 2025, 09:22	39,5 MB	Documento CSV
Marica_SUBPAV_MENSAL_EXAMES_2025-10.csv	2 de out. de 2025, 09:42	41,7 MB	Documento CSV
Marica_SUBPAV_MENSAL_EXAMES_2025-11.csv	4 de nov. de 2025, 08:47	42,8 MB	Documento CSV
Marica_SUBPAV_MENSAL_EXAMES_2025-12.csv	2 de dez. de 2025, 16:44	33,1 MB	Documento CSV
Marica_SUBPAV_MENSAL_EXAMES_2026-01.csv	3 de jan. de 2026, 06:44	30,9 MB	Documento CSV
Marica_SUBPAV_PLAN_ACOMP_MENSAL_DIA_2025-09.csv	2 de set. de 2025, 09:22	3,4 MB	Documento CSV
Marica_SUBPAV_PLAN_ACOMP_MENSAL_DIA_2025-10.csv	2 de out. de 2025, 09:41	3,4 MB	Documento CSV
Marica_SUBPAV_PLAN_ACOMP_MENSAL_DIA_2025-11.csv	4 de nov. de 2025, 08:46	3,3 MB	Documento CSV
Marica_SUBPAV_PLAN_ACOMP_MENSAL_DIA_2025-12.csv	2 de dez. de 2025, 16:43	3,5 MB	Documento CSV
Marica_SUBPAV_PLAN_ACOMP_MENSAL_DIA_2026-01.csv	3 de jan. de 2026, 06:44	3,5 MB	Documento CSV
Marica_SUBPAV_PLAN_ACOMP_MENSAL_HIPER_2025-09.csv	2 de set. de 2025, 09:22	7 MB	Documento CSV
Marica_SUBPAV_PLAN_ACOMP_MENSAL_HIPER_2025-10.csv	2 de out. de 2025, 09:41	6,8 MB	Documento CSV
Marica_SUBPAV_PLAN_ACOMP_MENSAL_HIPER_2025-11.csv	4 de nov. de 2025, 08:46	7,1 MB	Documento CSV
Marica_SUBPAV_PLAN_ACOMP_MENSAL_HIPER_2025-12.csv	2 de dez. de 2025, 16:44	7,2 MB	Documento CSV
Marica_SUBPAV_PLAN_ACOMP_MENSAL_HIPER_2026-01.csv	3 de jan. de 2026, 06:44	7,2 MB	Documento CSV

Legenda: diretório de arquivos fontes que foram extraídos do prontuário eletrônico.

Figura 2 – Tabelas da camada Bronze no schema vitacare_mvp

Tables_in_vitacare_mvp (csv_%)
csv_acompanhamento_diab
csv_acompanhamento_hiper
csv_atendimento_cid_param_bio
csv_cadastro_usuario_cap
csv_consolidada
csv_consultas_cap
csv_exames
csv_ficha_a_v2
csv_ficha_a_v2_ext
csv_listagem_login

Legenda: Arquivos importados para o MySQL, após o tratamento dos dados.

Figura 3 – Estrutura fiel da fonte e metadados de proveniência

MySQL Model* - EER Diagram

Schemas: consultas_pucio_carros, esquema_carros, consultas_dados_brutos*

Filter objects: Filter objects

Limit to 50000 rows

34 • describe csv_consultas_cap;

39

100% 28:36

Result Grid

Field	Type	Null	Key	Default	Extra
row_id	bigint unsigned	NO	PRI	NULL	auto_increment
carga_id	bigint unsigned	NO	MUL	NULL	
linha_origem	int unsigned	NO		NULL	
arquivo_origem	varchar(255)	NO		NULL	
data_importacao	datetime	NO		NULL	
competencia_extracao	char(7)	NO	MUL	NULL	
ap	text	YES		NULL	
unidade	text	YES		NULL	
src_id	text	YES		NULL	
cns	text	YES		NULL	
cpf	text	YES		NULL	
cnes	text	YES		NULL	
ine	text	YES		NULL	
dt_consulta	text	YES		NULL	
hora_consulta	text	YES		NULL	
profissional_consulta	text	YES		NULL	
cbo_presc	text	YES		NULL	

Legenda: descrição dos metadados

Figura 4 – Controle de carga por arquivo

MySQL Model* - EER Diagram

Schemas: consultas_pucio_carros, esquema_carros, consultas_dados_brutos*

Filter objects: Filter objects

Limit to 50000 rows

33 • show tables from vitacare_mvp like 'csv_*';

34 • describe csv_consultas_cap;

37

38 • SELECT fonte, tabela_destino, competencia_extracao, qtd_lidas, qtd_aceitas, qtd_rejeitadas, status FROM carga_arquivo

39 ORDER BY competencia_extracao, fonte;

41


100% 42:39

Result Grid

fonte	tabela_destino	competencia_extrac...	qtd_lidas	qtd_aceitas	qtd_rejeitad...	status
acompanhamento_diab	csv_acompanhamento_diab	2025-09	13935	13935	0	concluida
acompanhamento_hiper	csv_acompanhamento_hiper	2025-09	36180	36180	0	concluida
atendimento_cid_param_bio	csv_atendimento_cid_param_bio	2025-09	4135	4135	0	concluida
cadastro_usuario_cap	csv_cadastro_usuario_cap	2025-09	250176	250176	0	concluida
consolidada	csv_consolidada	2025-09	9605	9605	0	concluida
consultas_cap	csv_consultas_cap	2025-09	62008	62008	0	concluida
exames	csv_exames	2025-09	137848	137848	0	concluida
ficha_a_v2	csv_ficha_a_v2	2025-09	715881	0	715881	concluida
listagem_login	csv_listagem_login	2025-09	1066	1066	0	concluida
acompanhamento_diab	csv_acompanhamento_diab	2025-10	14220	14220	0	concluida
acompanhamento_hiper	csv_acompanhamento_hiper	2025-10	35432	35432	0	concluida
atendimento_cid_param_bio	csv_atendimento_cid_param_bio	2025-10	4666	4666	0	concluida
cadastro_usuario_cap	csv_cadastro_usuario_cap	2025-10	248924	248924	0	concluida
consolidada	csv_consolidada	2025-10	10404	10404	0	concluida
consultas_cap	csv_consultas_cap	2025-10	63122	63122	0	concluida
exames	csv_exames	2025-10	145163	145163	0	concluida
ficha_a_v2	csv_ficha_a_v2	2025-10	719508	0	719508	concluida
listagem_login	csv_listagem_login	2025-10	1078	1078	0	concluida
acompanhamento_diab	csv_acompanhamento_diab	2025-11	13703	13699	4	concluida
acompanhamento_hiper	csv_acompanhamento_hiper	2025-11	36949	36949	0	concluida
atendimento_cid_param_bio	csv_atendimento_cid_param_bio	2025-11	4668	4668	0	concluida
cadastro_usuario_cap	csv_cadastro_usuario_cap	2025-11	251013	251013	0	concluida
consolidada	csv_consolidada	2025-11	11223	11223	0	concluida
consultas_cap	csv_consultas_cap	2025-11	74725	74725	0	concluida
exames	csv_exames	2025-11	148618	148618	0	concluida
ficha_a_v2	csv_ficha_a_v2	2025-11	724011	0	724011	concluida
listagem_login	csv_listagem_login	2025-11	1113	1113	0	concluida

Legenda: Resultado da consulta de carga de arquivos

Figura 5 – Reconciliação da Bronze: Lida = aceitas + rejeitadas



The screenshot shows a SQL query editor with the following query:

```

41 •
42
43 • SELECT fonte, tabela_destino, SUM(qtd_lidas) AS total_lidas, SUM(qtd_aceitas) AS total_aceitas, SUM(qtd_rejeitadas) AS total_rejeitadas
44 FROM carga_arquivo
45 GROUP BY fonte, tabela_destino
46 ORDER BY fonte, tabela_destino;
47


```

The result grid shows the following data:

fonte	tabela_destino	total_lidas	total_aceit...	total_rejeitad...
acompanhamento_diab	csv_acompanhamento_diab	70900	70896	4
acompanhamento_hiper	csv_acompanhamento_hiper	182955	182955	0
atendimento_cid_param_bio	csv_atendimento_cid_param_bio	22809	22809	0
cadastro_usuario_cap	csv_cadastro_usuario_cap	1247718	1247718	0
consolidada	csv_consolidada	55035	55035	0
consultas_cap	csv_consultas_cap	312339	312339	0
exames	csv_exames	654224	654224	0
ficha_a_v2	csv_ficha_a_v2	2886460	0	2886460
ficha_a_v2_ext	csv_ficha_a_v2_ext	729696	729696	0
listagem_login	csv_listagem_login	3699	3699	0

Legenda: Resumo da importação por fonte no MySQL, com os totais de linhas lidas, aceitas e rejeitadas. Esse controle ajuda a identificar perdas durante a carga dos arquivos.

Figura 6 – Linhas rejeitada pro motivo, sem a linha original



The screenshot shows a SQL query editor with the following query:

```

46 ORDER BY fonte, tabela_destino;
47
48 • SELECT fonte, motivo_codigo, COUNT(*) AS qtd
49 FROM linha_rejeitada
50 GROUP BY fonte, motivo_codigo;
51

```

The result grid shows the following data:

fonte	motivo_codigo	qtd
acompanhamento_diab	Q_LINHA_MALFORMADA	4
ficha_a_v2	Q_LINHA_MALFORMADA	2886460

Legenda: Linhas rejeitadas na importação por problemas de formatação: 4 na fonte de acompanhamento de diabetes e 2.886.460 na Ficha A V2. As rejeições foram registradas para permitir sua conferência.

Figura 7 – Separação da Ficha A

The screenshot shows a SQL query editor with the following query:

```

56 • SELECT tabela_destino,competencia_extracao,SUM(qtd_aceitas) AS linhas_aceitas,SUM(qtd_rejeitadas) AS linhas_rejeitadas
57 FROM carga_arquivo
58 WHERE tabela_destino IN ('csv_ficha_a_v2','csv_ficha_a_v2_ext')
59 GROUP BY tabela_destino, competencia_extracao
60 ORDER BY tabela_destino, competencia_extracao;
61
62

```

Below the query, the 'Result Grid' shows the following data:

tabela_destino	competencia_extrac...	linhas_aceitas	linhas_rejeitad...
csv_ficha_a_v2	2025-09	0	715881
csv_ficha_a_v2	2025-10	0	719508
csv_ficha_a_v2	2025-11	0	724011
csv_ficha_a_v2	2025-12	0	727060
csv_ficha_a_v2_ext	2026-01	729696	0

Legenda: Resultado da importação da Ficha A por competência. O layout V2 teve todas as linhas rejeitadas entre setembro e dezembro de 2025. Já o layout estendido de janeiro de 2026 teve 729.696 linhas aceitas, sem rejeições.

3.5 Reconciliação da carga bruta

Os totais abaixo foram observados na execução local e devem ser os mesmos vistos nas Figuras 4 e 5. São contagens de carga, não amostras.


Fonte	Arquivos	Aceitas	Observação
cadastro_usuario_cap	5	1.247.718	Base do cadastro tratado
consultas_cap	5	312.339	Datas de evento em ago-dez/2025
listagem_login	5	3.699	jan/2026 sem linhas de dados
exames	5	654.224	Carregada; análise posterior
atendimento_cid_param_bio	5	22.809	Carregada; análise posterior
acompanhamento_diab	5	70.896	4 rejeições na carga
acompanhamento_hiper	5	182.955	
consolidada	5	55.035	Não somar às consultas
ficha_a_v2 (61 colunas)	4	0	Rejeição total
ficha_a_v2_ext (161 colunas)	1	729.696	Somente 2026-01

A listagem de login apresentou diferenças entre os períodos analisados. De setembro a novembro, os arquivos continham aproximadamente mil registros cada. Em dezembro, houve uma mudança no formato, com a inclusão do campo referente ao conselho e uma redução no número de registros. Já o arquivo de janeiro de 2026 não apresentou dados. Essas diferenças foram mantidas e documentadas na camada Bronze, sem realizar ajustes baseados em suposições.

4. Modelagem e catálogo de dados

4.1 Arquitetura medalhão

O processamento dos dados está organizado em três camadas. As camadas Bronze e Silver permanecem em um ambiente MySQL com acesso restrito, enquanto a Gold é armazenada no Databricks e utilizada para as análises. Os dados são preparados localmente e exportados em arquivos Parquet antes de serem enviados para a nuvem. Assim, o Databricks não recebe os arquivos CSV originais, mas apenas os dados que já passaram pelas etapas de preparação.



Legenda: Imagem gerada por IA

Camada	Onde	Conteúdo	Estado nesta entrega
Bronze	MySQL csv_*	Carga fiel + proveniência	Feita no ambiente local
Silver	MySQL *_ubs / exp_*	Conformação e códigos internos	Feita no ambiente local
Mapas	MySQL map_* / fila_*	Chaves de identidade	Locais; fora da nuvem
Gold	Databricks	Fato, dimensões e resumos	Persistida e consultada

Os campos paciente_id (P#####) e profissional_id (R#####) utilizam identificadores fictícios que permitem relacionar os registros sem expor diretamente a identidade dos pacientes e profissionais. Mesmo assim, esses dados continuam exigindo medidas de proteção. Os mapas que relacionam os identificadores e as filas de conflito permanecem no ambiente local e não são enviados para a nuvem.

4.2 Camada Silver

Na camada Silver, os dados da Bronze são organizados e preparados para análise, retirando das tabelas de saída as informações que permitem identificar diretamente os pacientes e

profissionais. Entre os campos removidos estão CPF, CNS, nome, nome social, endereço, nome da mãe, login, e-mail e outros dados pessoais e de contato.

A identificação dos pacientes é feita no ambiente local, por meio do cruzamento dos documentos disponíveis. Primeiro, utiliza-se o CPF; quando ele não está disponível, considera-se o CNS e, na ausência de ambos, o identificador presente na fonte original. Os casos em que há divergências de identidade são separados para revisão. O nome, por si só, não é utilizado para determinar que dois registros pertencem à mesma pessoa.


Como um mesmo paciente pode aparecer em diferentes meses e unidades de saúde, os dados foram distribuídos em tabelas com finalidades específicas. A tabela cadastro_pacientes_ubs registra o vínculo entre o paciente e a unidade de atendimento. Já a exp_paciente mantém um único código por pessoa, acompanhado de sua faixa etária. A exp_cadastro_presenca registra a presença mensal do paciente, evitando que os cadastros repetidos aumentem artificialmente a quantidade de pessoas contabilizadas.

O mesmo cuidado é aplicado ao plano de acompanhamento. Sua repetição ao longo dos meses não é considerada uma nova consulta, evitando a contagem indevida de atendimentos.

Tabela Silver	Grão observado	Linhas
exp_paciente	1 por paciente_id	236.912
cadastro_pacientes_ubs	1 por paciente e CNES	261.030
exp_cadastro_presenca	paciente × unidade × competência	1.244.746
exp_profissional	1 por profissional_id	893
consultas_ubs	1 por registro de consulta	312.339
exames_ubs	1 por linha de exame	654.224
atendimentos_cid_ubs	1 por atendimento	22.809
acompanhamento_diab_ubs	1 por linha do plano	70.896
acompanhamento_hiper_ubs	1 por linha do plano	182.955
ficha_a_ubs	layout estendido 2026-01	729.696


Havia 3.230 conflitos na fila de identidade de pacientes e 35 na fila de profissionais. No cadastro, 21.895 pacientes aparecem em mais de uma unidade. Nas consultas, 311.880 de 312.339 linhas receberam profissional_id (cerca de 99,9%). Essas medidas são locais e não autorizam publicar o mapa de nomes.

Figura 8 – Tabelas de camadas silver



Legenda: Tabelas de saída preparadas no MySQL para exportação ao Databricks. As tabelas de mapeamento de identidade e de controle de conflitos permanecem no ambiente local e não fazem parte da exportação.

Figura 9 – Saída Silver sem identificadores diretos




Legenda: Estrutura da tabela consultas_ubs, com identificadores pseudonimizados e campos usados nas análises, sem colunas de CPF, CNS, nome do paciente ou endereço.

4.3 Modelo analítico na nuvem

Foi desenvolvido um modelo estrela simples, no qual a tabela fato_consultas armazena um registro para cada consulta e se conecta a três dimensões: paciente, unidade de saúde e data.

Essas relações são feitas pelos campos `paciente_id`, `cnes` e pela correspondência entre `dt_consulta` e `data`.

Após a criação dos relacionamentos, foi realizada uma conferência que confirmou a manutenção dos 312.339 registros originais. Todas as consultas encontraram correspondência nas três dimensões, sem perda de registros nessa etapa.



A tabela `consultas_tratadas` é criada a partir da `consultas_ubs`, com a conversão do campo `dt_consulta`, originalmente armazenado como texto, para o formato DATE. Esses registros são utilizados na construção da tabela `fato_consultas`.

A `dim_data` reúne as 123 datas identificadas nas consultas, sem incluir os demais dias do calendário. A `dim_unidade` contém 27 unidades de saúde, identificadas por seus respectivos códigos CNES. Já a `dim_paciente` reúne 236.912 pacientes, com seus identificadores e faixas etárias.

A tabela `pacientes_grupos` organiza os pacientes que aparecem nos planos de acompanhamento em três categorias: aqueles que possuem apenas diabetes, os que possuem apenas hipertensão e os que apresentam as duas condições. Cada paciente é incluído em apenas um desses grupos, evitando a sobreposição na classificação.

Figura 10 – Entrada no Databricks e igualdade de contagens

The screenshot shows the Databricks interface with the 'Catálogo' (Catalog) on the left and the 'Explorador de Catálogos' (Catalog Explorer) on the right. The 'workspace' catalog is selected, and the 'entrada' volume is highlighted. The volume contains 12 Parquet files, including 'acompanhamento_diab_ubs.parquet', 'acompanhamento_hiper_ubs.parquet', 'atendimentos_cid_ubs.parquet', 'cadastro_pacientes_ubs.parquet', 'consultas_tratadas.parquet', 'consultas_ubs.parquet', 'exames_ubs.parquet', 'exp_cadastro_presenca.parquet', 'exp_paciente.parquet', 'exp_profissional.parquet', 'ficha_a_ubs.parquet', and 'pacientes_grupos.parquet'.

Legenda: Arquivos Parquet armazenados no volume de entrada do Databricks para criação das tabelas Delta.

Figura 11 – Catálogo e tabelas persistidas

The screenshot shows the Databricks interface with the 'Catálogo' (Catalog) on the left and the 'Descrição' (Description) on the right. The 'workspace' catalog is selected, and the 'vitacare_mvp' schema is highlighted. The schema contains 17 tables, including 'acompanhamento_diab_ubs', 'acompanhamento_hiper_ubs', 'atendimentos_cid_ubs', 'cadastro_pacientes_ubs', 'consultas_tratadas', 'consultas_ubs', 'dim_data', 'dim_paciente', 'dim_unidade', 'exames_ubs', 'exp_cadastro_presenca', 'exp_paciente', 'exp_profissional', 'fato_consultas', 'ficha_a_ubs', 'pacientes_grupos', and 'resumo_consultas_mensal'.

Legenda: Tabelas persistidas no schema workspace.vitacare_mvp, incluindo consultas tratadas, tabela fato, dimensões e resumo mensal das consultas.

Figura 12 – Modelo estrela após os relacionamentos

```

%sql
SELECT
    COUNT(*) AS registros_apos_ligacao,
    COUNT(*) - COUNT(p.paciente_id) AS sem_paciente,
    COUNT(*) - COUNT(u.cnes) AS sem_unidade,
    COUNT(*) - COUNT(d.data) AS sem_data
FROM workspace.vitacare_mvp.fato_consultas AS f
LEFT JOIN workspace.vitacare_mvp.dim_paciente AS p
    ON f.paciente_id = p.paciente_id
LEFT JOIN workspace.vitacare_mvp.dim_unidade AS u
    ON f.cnes = u.cnes
LEFT JOIN workspace.vitacare_mvp.dim_data AS d
    ON f.dt_consulta = d.data;
  
```

	registros_apos_ligacao	sem_paciente	sem_unidade	sem_data
1	312339	0	0	0

Legenda: Validação dos relacionamentos do modelo estrela. A ligação da tabela fato às dimensões manteve os 312.339 registros, sem consultas sem correspondência de paciente, unidade ou data.

4.4 Catálogo

O catálogo a seguir apresenta as tabelas e os campos do modelo analítico utilizados nas análises. Nesta versão, não foi incluída a descrição completa de todas as colunas das fontes de dados. As estruturas das tabelas locais podem ser consultadas nos arquivos SQL do projeto. Campos de identificação, como o CNES, são mantidos no formato texto, enquanto as datas das consultas, após a validação, são convertidas para o tipo DATE.

Tabela	Conteúdo e origem
consultas_tratadas	Consultas de consultas_ubs, com a data convertida para DATE.
fato_consultas	Registros de consultas_tratadas no modelo analítico.
dim_paciente	Identificador e faixa etária de exp_paciente; 236.912 pacientes.
dim_unidade	Unidades das consultas, sem repetição de CNES; 27 unidades.
dim_data	Datas encontradas nas consultas; 123 datas.
resumo_consultas_mensal	Quantidade de registros de consulta por ano e mês.
pacientes_grupos	Pacientes dos planos, em três grupos exclusivos.

Tabela	Campo	Tipo	Domínio observado
fato_consultas	consulta_id	STRING	Preenchido e distinto no recorte
fato_consultas	paciente_id	STRING	Ligação com dim_paciente
fato_consultas	profissional_id	STRING	Pode estar ausente (459 registros)
fato_consultas	cnes	STRING	Ligação com dim_unidade
fato_consultas	dt_consulta	DATE	01/08/2025 a 30/12/2025
fato_consultas	hora_consulta	STRING	HH:mm, entre 00:00 e 23:59
fato_consultas	competencia_extracao	STRING	AAAA-MM, de 2025-09 a 2026-01
dim_paciente	faixa_etaria	STRING	0–9 até 80–89 e 90+
dim_unidade	unidade	STRING	Nome da unidade associado ao CNES


dim_data	ano / mes	INT	Ano 2025; meses 8 a 12
resumo_consultas_mensal	registros_consultas	BIGINT	De 52.851 a 74.725
pacientes_grupos	grupo	STRING	Somente diabetes, somente hipertensão ou ambos

Após a importação dos arquivos Parquet para a nuvem, foi realizada uma conferência das quantidades de registros. Foram contabilizados 261.030 registros de cadastro, com 236.912 códigos de pacientes distintos, além de 312.339 consultas, 654.224 exames, 70.896 registros de diabetes, 182.955 de hipertensão e 22.809 de CID.

Também foram identificados 1.244.746 registros de presença cadastral, 236.912 pacientes, 893 profissionais e 729.696 registros da Ficha A.

A conferência mostrou que todas as consultas possuem um paciente_id correspondente na tabela exp_paciente. Esse resultado confirma que os registros estão corretamente relacionados do ponto de vista técnico, mas não garante, por si só, a identificação civil dos pacientes.

5. Pipeline de dado



No Databricks, o principal tratamento consiste em converter o campo dt_consulta para o formato DATE. Os identificadores continuam armazenados como texto, pois são utilizados para relacionar os registros, e não para realizar cálculos. Os campos de horário e competência também permanecem como texto, após a verificação de seus formatos. Esse processamento dá origem à tabela consultas_tratadas, que serve de base para a construção do modelo analítico e dos resumos utilizados nas análises.

Para acompanhar ou reproduzir o processamento, é necessário seguir algumas etapas:

1. Consultar os scripts de importação em scripts/ingest/, os de preparação em scripts/transform/ e os de exportação em scripts/export/.
2. Em um ambiente autorizado, gerar os arquivos Parquet e enviá-los ao volume de entrada do Databricks.

3. Configurar o catálogo, o schema e o volume utilizados pelo notebook ou ajustar os caminhos conforme o ambiente disponível.
4. Executar o notebook na sequência estabelecida: carregamento dos dados, validações, criação da tabela tratada, dimensões, tabela fato, resumos e análises.

Os dados originais não estão incluídos no repositório. Por esse motivo, a reprodução completa do processo exige acesso autorizado às fontes. O notebook e as evidências disponíveis registram os procedimentos realizados e os resultados obtidos.

É importante destacar que substituir um arquivo Parquet no volume de entrada não atualiza automaticamente a tabela Delta correspondente. Para que as alterações sejam refletidas nas análises, é necessário executar novamente as etapas de carregamento e processamento pertinentes.

Figura 14 – Notebook: ordem de carga, tratamento e persistência

The screenshot shows a Jupyter Notebook cell with Python code that interacts with a Spark environment. The code defines a list of table names, iterates over them, and for each name, it constructs a Parquet file path and a Delta table name. It then executes a SQL command to create the Delta table if it doesn't exist, using the data from the Parquet file. Afterward, it reads the Parquet file and the Delta table to compare their row counts. The results are appended to a list. The output of the notebook is a table with 9 rows, each representing one of the tables listed in the code. The table has four columns: 'tabela', 'registros_arquivo', 'registros_tabela', and 'conferencia'. All row counts match, and the 'conferencia' column shows 'OK' for all entries.

	tabela	registros_arquivo	registros_tabela	conferencia
1	acompanhamento_diab_ubs	70896	70896	OK
2	acompanhamento_hiper_ubs	182955	182955	OK
3	atendimentos_cid_ubs	22809	22809	OK
4	consultas_ubs	312339	312339	OK
5	exames_ubs	654224	654224	OK
6	exp_cadastro_presenca	1244746	1244746	OK
7	exp_paciente	236912	236912	OK
8	exp_profissional	893	893	OK
9	ficha_a_ubs	729696	729696	OK

9 linhas 54,071s de runtime Atualizada há Ontem

```

%sql
CREATE OR REPLACE TABLE workspace.vitacare_mvp.consultas_tratadas USING DELTA AS
SELECT consulta_id, paciente_id, profissional_id, cnes, unidade, ine, ap,
| CAST(TRY_TO_TIMESTAMP(TRIM(dt_consulta), 'dd/MM/yyyy') AS DATE) AS dt_consulta, hora_consulta, cbo_presc, competencia_extracao
FROM workspace.vitacare_mvp.consultas_ubs;

```

> [Ver desempenho \(1\)](#)

```

%sql
SELECT
| COUNT(*) AS total_registros,
| COUNT(*) - COUNT(dt_consulta) AS datas_ausentes,
| MIN(dt_consulta) AS primeira_data,
| MAX(dt_consulta) AS ultima_data
FROM workspace.vitacare_mvp.consultas_tratadas;

```

> [Ver desempenho \(1\)](#)

	1 ² total_registros	1 ² datas_ausentes	📅 primeira_data	📅 ultima_data
1	312339	0	2025-08-01	2025-12-30

Legenda: Etapas do pipeline no Databricks: leitura dos arquivos Parquet, criação das tabelas Delta e tratamento da data das consultas, com conferência das quantidades de registros.

6. Qualidade de dados

As verificações priorizaram os campos necessários às análises. As fontes são preservadas na Bronze. Divergências cadastrais foram registradas como limitação, sem exclusão automática do registro. Registros de plano sem identificador de paciente não entram na classificação dos grupos, porque não há como relacioná-los com segurança.

Verificação	Resultado observado
Identificador das consultas	312.339 preenchidos e distintos
Datas após conversão	Nenhuma ausente; 01/08/2025 a 30/12/2025
Horários	Nenhum ausente ou fora do formato verificado
Competência de extração	Nenhuma ausente; relação com o mês seguinte confirmada
Paciente e CNES nas consultas	Nenhum ausente
Profissional nas consultas	459 registros sem identificador, mantidos nas análises gerais
Dimensões	Chaves únicas; nenhuma consulta sem as três dimensões
Cadastro por unidade	2.026 bairros ausentes; 1 faixa etária ausente; 1.130 pacientes com mais de uma faixa
Plano de diabetes	717 registros sem identificador de paciente
Plano de hipertensão	1.641 registros sem identificador de paciente
Ficha A de 61 colunas	Rejeição total na Bronze; fora da análise
Fila de identidade (local)	3.230 conflitos de paciente; 35 de profissional

A verificação do campo `consulta_id` mostrou que não existem identificadores repetidos no período analisado. No entanto, isso não garante que um mesmo atendimento não tenha sido registrado mais de uma vez com identificadores diferentes.

Na tabela `exp_paciente`, cada paciente recebe uma única classificação de faixa etária, definida com base na última competência disponível no conjunto de dados. Durante a conferência, foram encontrados 1.130 códigos de pacientes com faixas etárias diferentes na tabela `cadastro_pacientes_ubs`. Algumas dessas diferenças não podem ser explicadas apenas pela mudança de idade ao longo do período. Portanto, embora cada paciente tenha uma única classificação na tabela final, isso não garante que as datas de nascimento informadas nas fontes estejam corretas.

Na análise realizada na nuvem, a faixa etária de 60 a 69 anos apresentou o maior volume observado, com 52.014 registros de consultas e 13.198 pacientes atendidos. A maior média de consultas por paciente foi registrada na faixa de 70 a 79 anos, com 4,00 consultas. Já a menor média foi observada entre os pacientes de 10 a 19 anos, com 2,67 consultas. Esses valores consideram todo o período analisado e incluem apenas os pacientes que tiveram pelo menos um atendimento.

Alguns cuidados também são necessários na interpretação dos resultados. Duas consultas realizadas em datas diferentes, na mesma unidade, indicam que o paciente utilizou o serviço mais de uma vez, mas não permitem afirmar que houve um retorno programado. Da mesma forma, a presença de um paciente no cadastro em dois meses diferentes indica a continuidade do seu registro, e não necessariamente a realização de atendimentos.

Outro ponto importante é que os indicadores calculados em períodos móveis, como a quantidade de consultas relacionadas ao diabetes nos últimos 12 meses, não devem ser somados entre diferentes competências, pois os períodos podem se sobrepor.

Além disso, o fato de um paciente aparecer apenas no plano de acompanhamento de diabetes ou de hipertensão não significa que ele não apresente a outra condição. Por fim, é importante considerar que a revisão de qualidade realizada não abrangeu todos os campos das fontes originais.

Figura 14 – Validação da fato e dos relacionamentos

	📄 consultas_distintas	📅 primeira_data	📅 ultima_data	📄 profissional_ausente	📄 consultas_sem_dimensao
1	312339	2025-08-01	2025-12-30	459	0

Legenda: Resumo das validações de qualidade das consultas, com quantidade de identificadores distintos, período dos atendimentos, ausência de profissional e correspondência com as dimensões.

Figura 15 – Qualidade cadastral em totais

	^A _C verificacao	¹ ₃ registros
1	Cadastro: bairro ausente	2026
2	Cadastro: faixa etária ausente	1
3	Plano de diabetes: paciente ausente	717
4	Plano de hipertensão: paciente ausen...	1641

Legenda: Campos ausentes nas bases analisadas: 2.026 registros sem bairro, um sem faixa etária e registros sem identificação de paciente nos planos de diabetes (717) e hipertensão (1.641). As contagens representam registros, não pacientes distintos.

7. Análise de dados

As respostas usam registros de consulta, não uma certificação de que cada linha seja um atendimento efetivo livre de duplicidade clínica. Até essa validação, o termo adotado é registro de consulta.

7.1 Volume de consultas

Outubro teve o maior volume e dezembro, o menor. Os dados mostram a variação e não permitem afirmar a causa.

Mês de 2025	Registros de consultas
Agosto	62.008
Setembro	63.122
Outubro	74.725
Novembro	59.633
Dezembro	52.851
Total	312.339

7.2 Pacientes e unidades

Foram identificados 88.992 pacientes atendidos em 27 unidades. Desses, 1.204 utilizaram mais de uma unidade: 1.187 passaram por duas e 17 por três. O total da rede não é a soma dos totais por unidade. Compartilhar pacientes não comprova encaminhamento entre unidades.


7.3 Diabetes e hipertensão

Os planos reúnem 41.016 pacientes distintos: 3.976 somente no plano de diabetes, 26.362 somente no de hipertensão e 10.678 em ambos. A classificação considera presença em qualquer competência carregada dos planos. Ela não demonstra que a pessoa já pertencia ao plano na data de cada consulta.

Grupo	Consultas	Pacientes atendidos	Média por paciente atendido
Ambos os planos	38.453	8.199	4,69
Somente diabetes	11.440	2.696	4,24
Somente hipertensão	68.040	16.781	4,05

Os pacientes presentes em ambos os planos tiveram a maior média de consultas. O grupo somente de hipertensão teve o maior volume total. As médias consideram apenas quem teve consulta no período e não permitem concluir gravidade da doença ou qualidade do acompanhamento. As consultas podem ter ocorrido por outros motivos.

Figura 16 – Média de consultas por grupo de acompanhamento



Legenda: Média de consultas por paciente atendido nos grupos de acompanhamento, de agosto a dezembro de 2025. A média considera apenas pacientes com consultas no período, independentemente do motivo do atendimento.

Figura 17 – Volume mensal de registros de consulta

divergências. A análise territorial também deverá ser concluída, tomando cuidado para que os relacionamentos entre tabelas não provoquem a duplicação das consultas. Além disso, será necessário organizar um processo de atualização periódica dos dados.

A documentação deverá incluir a autorização institucional para utilização dos dados, quando ela estiver disponível. O simples acesso aos arquivos não significa que seu uso esteja automaticamente autorizado.

Por fim, o manifesto de exportação precisa ser complementado para contemplar os dez arquivos enviados à nuvem. Para cada arquivo, deverão ser registrados a quantidade de registros, as colunas, a versão dos scripts utilizados, a data de exportação e o hash. Essa atualização é necessária porque a primeira versão do manifesto mencionava apenas a Ficha A, sem apresentar informações sobre os demais arquivos exportados.

8.2 Autoavaliação

O desenvolvimento deste trabalho possibilitou estruturar um fluxo de dados, desde a preparação dos arquivos originais até a construção das tabelas e a realização das análises no Databricks. Com isso, foi possível comparar os atendimentos entre os meses, identificar a quantidade de pacientes distintos, verificar aqueles que utilizaram mais de uma unidade de saúde e analisar os grupos incluídos nos planos de acompanhamento.

Durante o desenvolvimento, algumas dificuldades exigiram maior atenção, principalmente na identificação de um mesmo paciente em arquivos diferentes, no tratamento das divergências cadastrais e na separação entre o mês de extração dos arquivos e a data em que os atendimentos realmente ocorreram. As verificações realizadas ao longo do processo permitiram identificar inconsistências e estabelecer limites para a interpretação dos resultados, evitando conclusões que não poderiam ser confirmadas pelos dados disponíveis.

Nesta etapa, o objetivo principal foi demonstrar o funcionamento do fluxo de processamento e responder a parte das questões propostas, utilizando resultados que pudessem ser conferidos. Para isso, a camada Bronze manteve os dados originais no MySQL local, preservando as informações de origem e registrando os dados rejeitados. A camada Silver ficou responsável pela preparação dos dados e pela geração de tabelas pseudonimizadas. Já a camada Gold, no Databricks, armazenou o modelo estrela e os resumos utilizados nas análises apresentadas.

As questões que não puderam ser respondidas nesta entrega foram mantidas no relatório, acompanhadas das justificativas e das etapas necessárias para sua conclusão. Dessa forma, o trabalho apresenta tanto os resultados alcançados quanto os pontos que ainda precisam ser desenvolvidos.

Durante o projeto, foi desafiador aprender a organizar os dados e transformar os arquivos em tabelas para análise no Databricks. Minha maior dificuldade não foi com SQL ou Python, mas com

a própria ferramenta, principalmente para entender a organização dos catálogos, do workspace e das tabelas.

Mesmo com um período de análise curto, os dados trouxeram observações que despertaram meu interesse. Em algumas unidades, apareceram picos de atendimento em determinados dias, com volumes que pareceram elevados considerando meu conhecimento sobre o porte da unidade, a quantidade de profissionais e o número de pacientes cadastrados. Em alguns casos, esses volumes superaram os de unidades maiores. Esses resultados merecem uma investigação mais aprofundada, pois ainda não é possível explicar suas causas apenas com as análises realizadas.

O projeto também me levou a registrar novas perguntas. Acredito que, com mais tempo e um período maior de dados, poderei identificar outros padrões e entender melhor os valores que fogem do comportamento habitual. Considero essa primeira versão um ponto de partida para continuar o estudo e conhecer melhor a utilização das unidades de saúde.

Figura 18 – Síntese visual do fluxo medalhão

